

# Proyecto de Clasificación Supervisada

Métodos para el Análisis de Datos I

Lucas Calierno

6 de julio de 2026

## Índice

|                                          |          |
|------------------------------------------|----------|
| <b>1. Introducción</b>                   | <b>2</b> |
| <b>2. Exploración y preprocesamiento</b> | <b>2</b> |
| <b>3. Entrenamiento del modelo</b>       | <b>2</b> |
| <b>4. Análisis de resultados</b>         | <b>3</b> |
| <b>5. Conclusiones</b>                   | <b>3</b> |

# 1. Introducción

El aprendizaje no supervisado tiene como objetivo descubrir patrones o estructuras presentes en los datos sin disponer de etiquetas previamente conocidas. Una de sus aplicaciones más importantes es el *clustering*, que busca agrupar observaciones similares dentro de un mismo conjunto de datos.

En este trabajo se aplicó el algoritmo **K-Means** sobre un conjunto de datos correspondiente a clientes de un centro comercial (*Mall Customers*), con el objetivo de identificar segmentos de clientes a partir de sus características demográficas y económicas.

El desarrollo del trabajo se dividió en tres etapas: exploración y preprocesamiento de los datos, entrenamiento del modelo de clustering e interpretación de los grupos obtenidos.

# 2. Exploración y preprocesamiento

Como primera etapa se realizó un análisis exploratorio del conjunto de datos.

Se verificó la estructura del dataset mediante funciones descriptivas, comprobando que el conjunto contiene 200 observaciones y cinco variables: identificador del cliente, género, edad, ingreso anual y *Spending Score*.

Posteriormente se evaluó la calidad de los datos, verificándose que el conjunto no presenta valores faltantes ni registros duplicados.

A continuación se analizaron las distribuciones de las variables mediante histogramas y diagramas de caja, junto con una matriz de correlación y un *pairplot*, permitiendo obtener una primera aproximación a la estructura del conjunto de datos.

Como parte del preprocesamiento se eliminaron las variables que no aportaban información al modelo, codificando posteriormente la variable categórica correspondiente al género mediante variables binarias. Finalmente, todas las variables fueron estandarizadas utilizando `StandardScaler`, con el objetivo de evitar que diferencias de escala influyeran sobre el cálculo de las distancias utilizadas por K-Means.

El conjunto de datos procesado fue almacenado para su utilización en la etapa de modelado.

# 3. Entrenamiento del modelo

Una vez obtenido el conjunto de datos preprocesado se aplicó el algoritmo K-Means.

Dado que este algoritmo requiere especificar previamente el número de clusters, se evaluaron distintos valores de  $k$  utilizando dos criterios:

- Método del codo.
- Coeficiente de silueta.

El método del codo mostró un cambio de pendiente alrededor de  $k = 4$ , mientras que el coeficiente de silueta presentó un incremento progresivo sin mostrar un máximo claramente definido dentro del rango analizado.

Considerando ambas métricas y buscando un equilibrio entre calidad del agrupamiento e interpretabilidad de los resultados, se seleccionó un total de cuatro clusters para el modelo final.

Posteriormente se entrenó K-Means y se asignó cada cliente al grupo correspondiente.

Con el objetivo de facilitar la visualización de los resultados, se aplicó además un Análisis de Componentes Principales (PCA), proyectando los datos sobre dos dimensiones para representar gráficamente la segmentación obtenida.

## 4. Análisis de resultados

Para interpretar los grupos obtenidos se volvió a utilizar el conjunto de datos en su escala original, incorporando únicamente la etiqueta del cluster asignado por el algoritmo.

Se analizaron las estadísticas descriptivas de cada grupo, junto con diagramas de caja para las principales variables y la distribución del género dentro de cada cluster.

Los resultados mostraron diferencias principalmente en la edad y en el nivel de gasto de los clientes, mientras que el ingreso anual presentó un comportamiento relativamente similar entre los distintos grupos.

Asimismo, se observó una separación prácticamente completa según el género. Esto indica que dicha variable tuvo una influencia importante durante el proceso de agrupamiento, generando inicialmente una diferenciación entre hombres y mujeres. Posteriormente, dentro de cada uno de estos grupos, el algoritmo identificó subgrupos diferenciados principalmente por edad y nivel de gasto.

Este comportamiento refleja la influencia que poseen las variables seleccionadas sobre los algoritmos basados en distancia, como K-Means, y pone de manifiesto la importancia de una adecuada selección de características durante la etapa de preprocesamiento.

## 5. Conclusiones

En este trabajo se aplicó una metodología completa de segmentación no supervisada utilizando el algoritmo K-Means.

El proceso incluyó la exploración y preparación de los datos, la selección del número de clusters mediante métricas de evaluación, el entrenamiento del modelo y la interpretación de los grupos obtenidos.

Los resultados permitieron identificar cuatro segmentos diferenciados de clientes, observándose una fuerte influencia de la variable género durante el proceso de agrupamiento. Asimismo, se comprobó que la edad y el nivel de gasto constituyen variables relevantes para caracterizar los distintos perfiles de clientes.

Finalmente, este trabajo permitió aplicar de manera práctica los principales conceptos de aprendizaje no supervisado estudiados durante el curso, mostrando cómo las técnicas de clustering pueden utilizarse para descubrir patrones presentes en los datos sin necesidad de contar con etiquetas previamente conocidas.