

Proyecto de Clasificación Supervisada

Métodos para el Análisis de Datos I

Lucas Calierno

4 de julio de 2026

Índice

1. Introducción	2
2. Descripción del conjunto de datos	2
3. Metodología	2
4. Métricas de evaluación	3
5. Resultados	3
6. Discusión	3
7. Limitaciones	3
8. Conclusiones	4

1. Introducción

El aprendizaje supervisado constituye una de las áreas más importantes del análisis de datos y del aprendizaje automático. En los problemas de clasificación, el objetivo consiste en construir un modelo capaz de asignar nuevas observaciones a una categoría previamente definida a partir de un conjunto de ejemplos etiquetados.

En este trabajo se aborda un problema de clasificación binaria utilizando el conjunto de datos *Breast Cancer Wisconsin*, disponible en la biblioteca `scikit-learn`. Dicho conjunto contiene mediciones obtenidas a partir de imágenes digitalizadas de biopsias mamarias, con el objetivo de clasificar cada tumor como benigno o maligno.

El propósito del proyecto es comparar distintos algoritmos de clasificación supervisada y analizar su desempeño mediante diferentes métricas de evaluación.

2. Descripción del conjunto de datos

El conjunto de datos utilizado posee 569 observaciones y 30 variables predictoras, todas ellas numéricas. Cada variable corresponde a una característica morfológica obtenida de la imagen del tumor, tales como radio, perímetro, área, textura o suavidad.

La variable respuesta posee dos clases:

- Tumor maligno.
- Tumor benigno.

Durante el análisis exploratorio se verificó que el conjunto no presenta valores faltantes y que el desbalance entre clases no resulta severo, por lo que no fue necesario aplicar técnicas específicas de balanceo.

Asimismo, se observó la existencia de correlaciones elevadas entre algunas variables, comportamiento esperable debido a que muchas mediciones provienen de una misma imagen.

3. Metodología

Inicialmente se realizó una exploración del conjunto de datos mediante estadísticas descriptivas, análisis de correlaciones y estudio de la distribución de las clases.

Posteriormente, el conjunto fue dividido en entrenamiento y prueba mediante una partición estratificada, preservando la proporción de cada clase en ambos subconjuntos.

Para el entrenamiento de los modelos se utilizó la clase `Pipeline` de `scikit-learn`, lo que permite encapsular el flujo completo de entrenamiento y facilita la reproducibilidad del proceso.

Asimismo, la selección de hiperparámetros se realizó mediante `GridSearchCV` utilizando validación cruzada de cinco particiones.

Los modelos comparados fueron:

- Árbol de Decisión.
- Random Forest.

Finalmente, ambos modelos fueron evaluados sobre el conjunto de prueba utilizando diversas métricas de desempeño.

4. Métricas de evaluación

Para comparar los modelos se emplearon las siguientes métricas:

- Accuracy.
- Precision.
- Recall.
- F1-score.
- Área bajo la curva ROC (ROC-AUC).

Además, se analizaron las matrices de confusión y las curvas ROC correspondientes a cada clasificador.

Estas métricas permiten obtener una evaluación más completa del desempeño de los modelos que la proporcionada únicamente por la exactitud (Accuracy).

5. Resultados

Los resultados obtenidos muestran que ambos algoritmos presentan un desempeño elevado sobre el conjunto de prueba.

No obstante, el modelo Random Forest obtuvo mejores valores en la mayoría de las métricas consideradas, reflejando una mayor capacidad de generalización respecto del Árbol de Decisión.

Asimismo, el análisis de importancia de variables permitió identificar cuáles de las características aportan mayor información al proceso de clasificación, facilitando la interpretación del modelo.

6. Discusión

Los resultados obtenidos coinciden con lo esperado desde el punto de vista teórico.

Mientras que un Árbol de Decisión individual puede presentar una elevada varianza y tender al sobreajuste, Random Forest reduce este problema mediante la combinación de múltiples árboles entrenados sobre diferentes subconjuntos de datos.

Sin embargo, el Árbol de Decisión continúa siendo un modelo altamente interpretable, característica que puede resultar especialmente valiosa en aplicaciones donde es necesario justificar cada decisión tomada por el algoritmo.

En consecuencia, la elección del modelo depende no solamente de su desempeño predictivo sino también del contexto de aplicación y del equilibrio buscado entre precisión e interpretabilidad.

7. Limitaciones

El presente trabajo presenta algunas limitaciones.

En primer lugar, únicamente se analizó un conjunto de datos, por lo que las conclusiones obtenidas no necesariamente pueden generalizarse a otros problemas de clasificación.

Por otra parte, solamente se compararon dos algoritmos de aprendizaje supervisado. Existen otros modelos, como Máquinas de Vectores de Soporte o Redes Neuronales, cuyo desempeño podría resultar superior dependiendo del problema considerado.

Finalmente, aunque la selección de hiperparámetros se realizó mediante validación cruzada, la evaluación final se efectuó sobre una única partición entrenamiento/prueba.

8. Conclusiones

En este trabajo se desarrolló un proyecto completo de clasificación supervisada utilizando herramientas de la biblioteca `scikit-learn`.

Se realizó un análisis exploratorio del conjunto de datos, seguido del entrenamiento y comparación de dos modelos de clasificación mediante validación cruzada y búsqueda de hiperparámetros.

Los resultados obtenidos muestran que Random Forest alcanzó el mejor desempeño general, constituyendo la alternativa más adecuada para este conjunto de datos.

Finalmente, el desarrollo del proyecto permitió aplicar los principales conceptos estudiados durante la unidad, incluyendo el uso de `Pipeline`, `GridSearchCV`, métricas de evaluación y comparación de modelos de clasificación.