

Ejercicios Propuestos

Unidad 3: Regresión y Correlación

1. Ejercicios Propuestos

1.1. Ejercicio 1: Regresión lineal simple

Se midió la altura (X , en cm) y el peso (Y , en kg) de 15 estudiantes. Los datos se resumen:

$$\bar{X} = 170, \quad \bar{Y} = 68, \quad S_{XX} = 450, \quad S_{YY} = 280, \quad S_{XY} = 330.$$

Tareas

1. Calcular las estimaciones $\hat{\beta}_0$ y $\hat{\beta}_1$.
2. Interpretar los coeficientes.
3. Calcular R^2 .
4. Predecir el peso de un estudiante de 175 cm.

1.

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = 0,73$$

$$\hat{\beta}_0 = \bar{Y} - \beta_1 \bar{X} = -56,66$$

2. El parámetro β_1 indica la pendiente de la recta. El modelado predice que por cada centímetro adicional en la altura, el peso aumenta en 0,73Kg.

El parámetro β_0 indica la ordenada al origen de la recta. No tiene interpretación práctica, pues el caso altura=0 es un caso de extrapolación salvaje.

3.

$$R^2 = \frac{S_{xy}^2}{S_{xx}S_{yy}} = 0,86$$

El parámetro R^2 indica que el modelo explica aproximadamente un 86 % de la variedad del peso por la altura

4. El peso de un estudiante de 175cm se calcula reemplazando x por 175 en la ecuación

$$y = \beta_0 + \beta_1 * 175 = 71,66$$

1.2. Ejercicio 2: Diagnóstico

Ajustaste una regresión lineal y observaste en el gráfico de residuos vs. ajustados un patrón en forma de embudo.

Preguntas

1. ¿Qué supuesto se viola?
2. ¿Qué consecuencias tiene?
3. Proponer dos posibles soluciones.

Respuestas:

1. El supuesto que se viola al observar un patrón en forma de embudo es el supuesto de homocedasticidad. Esto es que la Varianza de los errores no es constante.
2. Como consecuencia, los errores estándar pueden estar mal estimados y las predicciones pueden ser erróneas
3. Como posibles soluciones, se puede transformar la variable respuesta, mediante el uso de $(\text{Log}(Y))$ o $\sqrt{(Y)}$. Otra posible solución, podría ser optar por cambiar de modelado, como un modelo de regresión por medio de mínimos cuadrados ponderados, o incluso un modelo de regresión polinomial.

1.3. Ejercicio 3: Regresión múltiple

Se ajustó un modelo de regresión múltiple para predecir el precio de autos usados (Y) en función de:

- X_1 : antigüedad (años).
- X_2 : kilometraje (miles).
- X_3 : potencia del motor (HP).

El modelo ajustado es

$$\hat{Y} = 25000 - 1500X_1 - 0,05X_2 + 100X_3.$$

Tareas

1. Interpretar cada coeficiente.
2. Si un auto tiene 3 años, 50 000 km y 150 HP, ¿cuál es su precio estimado?
3. ¿Qué variable tiene mayor impacto absoluto en el precio?

Respuestas: 1. Los coeficientes evalúan como varía el precio de un auto según su respectiva variable. El coeficiente 25000 es el precio base para un auto sin antigüedad, sin kilometraje, pero con 0HP, lo cual no es razonable. El coeficiente -1500 acompañando al X_1 indica que por cada año de antigüedad del auto, el precio cae en 1500. El coeficiente -0.05 que acompaña al X_2 indica que por cada kilometro, el precio del auto cae en 0.05. Por otro lado, el 100 acompañando el X_3 indica que por cada caballo de fuerza adicional, el precio del auto se ve incrementado en 100.

2. Si un auto tiene 3 años, 50000km y 150 HP, el precio estimado se obtiene reemplazando en la fórmula lineal los parámetros.

$$y = 35000 - 1500 * 3 - 0,05 * 5000 + 100 * 150 = 33000$$

Luego, el precio es de 33000.

3. La variable con mayor impacto es la antigüedad (X_1), debido a que tiene el coeficiente mas alto. Esto provoca que un pequeño cambio en antigüedad, resulta en un gran cambio en el precio final.

1.4. Ejercicio 4: Multicolinealidad

Se ajustó un modelo con las variables: estatura (X_1), peso (X_2) y circunferencia de cintura (X_3) para predecir la presión arterial. Los VIF son:

$$VIF_1 = 2,3, \quad VIF_2 = 15,2, \quad VIF_3 = 14,8.$$

Preguntas

1. ¿Hay multicolinealidad? ¿Entre qué variables?
2. ¿Qué harías para solucionarlo?

1. Podemos decir que existe una fuerte colinealidad asociadas a las variables X_2 y X_3 , pues su VIF es mayor a 10. Por otro lado, el VIF de X_1 es muy chico, por lo que no presenta problemas importantes.

2. Para solucionarlo propondría eliminar alguna de las dos variables, o crear una nueva variable auxiliar, que sea una combinación de ambas.

1.5. Ejercicio 5: Correlación

Se calculó la correlación de Pearson entre horas de estudio (X) y calificación en un examen (Y) para 50 estudiantes, obteniendo $r = 0,72$.

Tareas

1. Interpretar el valor de r .
2. Realizar el test de significancia ($\alpha = 0,05$).
3. Calcular R^2 y explicar su significado.
4. ¿Podemos concluir que estudiar más causa mejores notas? Justificar.

1. El valor de r de 0,72 indica una significativa correlación lineal positiva. Es decir, que el modelado predice que a mayor horas de estudio, mayor la calificación en los exámenes.

2.

$$H_0 : \rho = 0$$

$$H_1 : \rho \neq 0$$

El estadístico a usar es

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} \simeq 7,19$$

El valor crítico bilateral para $\alpha = 0,05$ es aproximadamente 2.01 para una t de student con 48 grados de libertad. Como el valor de mi estadístico es mayor que el valor crítico, entonces se rechaza H_0 con una significancia del 95 %

3.

$$R^2 = r^2 = 0,72^2 = 0,5184.$$

El valor de $R^2 \approx 0,51$ indica que aproximadamente el 51,8 % de la variabilidad de las calificaciones puede explicarse mediante una relación lineal con las horas de estudio.

4. Si bien podemos decir que existe cierta asociación entre la variabilidad de las calificaciones y las horas de estudio, este modelo no tiene en cuenta muchos posibles factores, como la capacidad del alumno, la preparación previa, entre otros factores, que pueden explicar el otro 49,2 % de las calificaciones.